

Текущая реализация SVD-решателя

По ADP/solver/SVD.py; обозначения SVD_solver.tex

1. Вход и локальная оценка. Функция `solve` выполняет один шаг для многоиндексного базиса $P \in \mathbb{R}^{m \times d}$ и CPU-статистик $U = (U_j) \in \mathbb{R}^{J \times p \times d}$, $I = (I_j) \in \mathbb{R}^{J \times p}$. Проверяются входы; при отсутствии `mass` используются единичные массы N_j , иначе массы должны быть конечными и положительными. Базис ортонормируется. Через `_local_refit` вычисляются minimum-norm решения $g_j = \arg \min_g \|I_j - U_j P^\top g\|_2^2$ (пакетное SVD, с `lstsq` для чувствительных к потере ранга центров). Эти g_j затем фиксированы на весь внутренний шаг: полного чередования локальных и глобальных оценок внутри `solve` нет.

2. Два режима и начальное состояние. При $\lambda = \text{lambda_prox} \geq 0$ минимизируется $F(B) = \sum_j N_j \|I_j - U_j B^\top g_j\|_2^2 + \lambda \|B - P\|_F^2$. По умолчанию `low_rank_target="matrix"` ограничивает $\text{rank}(B) \leq r$, $1 \leq r < m$. Режим "correction" ограничивает $\text{rank}(B - P) \leq r$, $0 \leq r < m$. Для единого описания положим

$$(X, I_j^0, P^0) = \begin{cases} (B, I_j, P), & \text{matrix,} \\ (\Delta, I_j - U_j P^\top g_j, 0), & B = P + \Delta, \text{ correction.} \end{cases}$$

В обоих случаях начинают с $X = 0$ и пустых факторов $X = A \text{diag}(\sigma) V^\top$, $A^\top A = V^\top V = \text{Id}_k$. Кэш $W_j = U_j V$ позволяет считать предсказания без сборки X на каждом шаге. `_FlatU` хранит непрерывный массив U и его представление $(Jp) \times d$ для матричных действий, при необходимости копируя вход.

3. Инициализация очередной компоненты. Для $k = 1, \dots, r$ вычисляются

$$e_j = I_j^0 - W_j \text{diag}(\sigma) A^\top g_j, \quad Q = \sum_j N_j g_j (U_j^\top e_j)^\top + \lambda (P^0 - X).$$

Код строит $Q_\perp = Q - (QV)V^\top$ и находит ведущий собственный вектор u малой матрицы $Q_\perp Q_\perp^\top$. При ведущем значении $\mu > 0$ начальное направление равно $v = Q_\perp^\top u / \sqrt{\mu}$; при $\mu \leq 0$ следует остановка `zero_gradient`. Так новое начало выбирается вне уже найденного правого пространства. Ортогональность к V не навязывается последующим попеременным итерациям.

4. Попеременное уточнение и контроль линейного решения. При фиксированном Q повторяются нормированные решения

$$\left[\sum_j N_j \|U_j v\|_2^2 g_j g_j^\top + \lambda \text{Id}_m \right] \tilde{a} = Qv, \quad a = \tilde{a} / \|\tilde{a}\|_2, \\ H_a \tilde{v} = Q^\top a, \quad H_a = \sum_j N_j (a^\top g_j)^2 U_j^\top U_j + \lambda \text{Id}_d, \quad v = \tilde{v} / \|\tilde{v}\|_2.$$

Малые системы решаются Холецким, с запасным `lstsq`. При $\lambda > 0$ и $d \leq 128$ по умолчанию система для $\tilde{v}$ также решается Холецким; взвешенный дизайн собирается блоками до 16 MiB. Иначе используется матрично-свободный LSMR для $\min_x \|A_a x - t\|_2^2 + \lambda \|x - z\|_2^2$, где $(A_a x)_j = \sqrt{N_j} (a^\top g_j) U_j x$, $t_j = \sqrt{N_j} e_j$, $z = (P^0 - X)^\top a$. `warm_start=True` переиспользует предыдущий $\tilde{v}$ внутри поиска пары; расширенная задача поправки сохраняет центр штрафа z . Опция `precondition_v` масштабирует оба блока по диагонали $A_a^\top A_a + \lambda \text{Id}_d$; `adaptive_krylov` меняет допуск LSMR.

Поиск заканчивается при $1 - |v_{t+1}^\top v_t| < \text{inner_tol}$ (по умолчанию 10^{-6}) либо после `inner_maxiter` шагов (20). Последнее ненормированное решение проверяется по

$$\eta = \frac{\|A_a^\top (A_a \tilde{v} - t) + \lambda (\tilde{v} - z)\|_2}{\max(1, \|A_a^\top t + \lambda z\|_2)} \leq \max(10^{-7}, 10 \text{ inner_tol}).$$

При неудаче ускоренных вариантов выполняется строгое LSMR-уточнение; оставшаяся неприемлемая невязка вызывает ошибку. Затем a ещё раз точно переоценивается для последнего v , даже если достигнут лимит итераций.

5. Добавление, сжатие и принятие. Вычисляются $R = a^\top Qv$, $D = \sum_j N_j(a^\top g_j)^2 \|U_j v\|_2^2 + \lambda$, масштаб R/D и ожидаемый выигрыш $\gamma = R^2/D$. При неположительном D следует `zero_curvature`; при $\gamma/\max(1, F) < \text{rank_tol}$ (по умолчанию 10^{-8}) — `rank_tolerance`. Иначе к факторам добавляется компонента, выполняются сокращённые QR и SVD малой матрицы произведения QR-факторов. Если новое сингулярное значение не превышает $\epsilon \max(m, d) s_{\max}$, следует `no_rank_growth`. Кэш $U_j V$ преобразуется через QR-факторы; при $\text{cond}(R_R) > 10^6$ пересчитывается непосредственно.

Для новых ортонормированных a_ℓ, v_ℓ совместно решается $M\sigma = h$:

$$M_{\ell t} = \sum_j N_j(a_\ell^\top g_j)(a_t^\top g_j)(U_j v_\ell)^\top (U_j v_t) + \lambda \delta_{\ell t},$$

$$h_\ell = \sum_j N_j(a_\ell^\top g_j)(I_j^0)^\top U_j v_\ell + \lambda a_\ell^\top P^0 v_\ell.$$

Кандидат принимается при конечном функционале и росте не более $64\epsilon \max(1, F)$, где ϵ — машинная точность; иначе возникает ошибка. После принятия потеря численного ранга также завершает цикл. История функционала, выигрыши, ранги, остановки и невязки сохраняются.

6. Возврат базиса и коэффициентов. `solve_fixed_coefficients` возвращает сырую B и диагностику. `solve` в режиме `matrix` берёт активные правые направления по убыванию $|\sigma_\ell|$ и дополняет их до m из SVD матрицы $P - (PV_{\text{act}})V_{\text{act}}^\top$; при нулевом ранге возвращает P . В режиме `correction` строится QR базиса $(P + \Delta)^\top$ с проверкой полного ранга строк; при нулевой поправке сохраняется P . На итоговом базисе заново оцениваются локальные коэффициенты. Возвращается `HPAOResult`: базис, коэффициенты, диагностика, включая взвешенную ошибку данных и число локальных потерь ранга. Убывание внутреннего F не гарантирует его убывание после ортонормирования или глобальную оптимальность; дополнение из P не восстанавливает новые EDR-направления.

Опциональная спектральная метрика. `metric_power=0` оставляет описанный штраф Фробениуса. При $\nu = \text{metric_power} \in \{1/2, 1\}$ код задаёт $K = \alpha^2 \text{Id}_d + P^\top \Lambda P$ (full) либо $K = \alpha^2(\text{Id}_d - P^\top P) + P^\top \Lambda P$ (orthogonal), $A = \rho \text{Id}_d + (1 - \rho)(K/\|K\|_2)^\nu$, где $\rho = \text{metric_floor}$. Требуется положительная определённость, $\alpha > 0$ и нормированный спектр Λ . Штраф становится $\lambda \|(B - P)A^{1/2}\|_F^2$; тот же цикл применяется к $BA^{1/2}$, $PA^{1/2}$, $U_j A^{-1/2}$. Затем координаты возвращаются обратно, и базис формируется в исходном пространстве. Плотная $d \times d$ метрика не строится, но хранится дополнительный массив размера U .