

SVD-решатель: последовательность алгоритма

Краткое изложение в обозначениях SVD/SVD_solver.tex

Задача и входные данные. Описывается один внутренний шаг ADP: текущий базис $P \in \mathbb{R}^{m \times d}$, $PP^T = \text{Id}_m$, и локальные величины $g_j \in \mathbb{R}^m$, $I_j \in \mathbb{R}^p$, $U_j \in \mathbb{R}^{p \times d}$, $N_j > 0$, $j = 1, \dots, J$, фиксированы. Задаются $\lambda > 0$, предельный ранг $1 \leq r \leq m$, допуски и предел числа внутренних итераций. Решатель приближённо минимизирует

$$F(B) = \sum_{j=1}^J N_j \|I_j - U_j B^T g_j\|_2^2 + \lambda \|B - P\|_F^2, \quad \text{rank}(B) \leq r.$$

Первое слагаемое согласует глобальную матрицу с локальными откликами; второе удерживает её около текущего P и делает условные линейные системы положительно определёнными. Статистики I_j, U_j имеют согласованную нормировку; масса N_j используется как вес, а не повторный множитель статистик.

1. Инициализация и невязка. Положить $B_0 = 0$; список компонент пуст. Перед добавлением компоненты $k = 1, \dots, r$ для $B = B_{k-1}$ вычислить

$$e_j = I_j - U_j B^T g_j, \quad Q(B) = \sum_j N_j g_j (U_j^T e_j)^T + \lambda (P - B).$$

Здесь e_j — невязки данных, а $Q = -\frac{1}{2} \nabla F(B)$ — матричное направление уменьшения функционала. Ищем добавку $\sigma a v^T$, где $a \in \mathbb{R}^m$, $v \in \mathbb{R}^d$, $\|a\|_2 = \|v\|_2 = 1$. Одна такая добавка увеличивает ранг не более чем на единицу.

2. Поиск пары направлений. Выбрать единичное начальное v : например, ведущий правый сингулярный вектор Q или случайный вектор. При неизменных B, e_j, Q попеременно решать

$$\begin{aligned} G_v \tilde{a} &= Qv, & G_v &= \sum_j N_j \|U_j v\|_2^2 g_j g_j^T + \lambda \text{Id}_m, & a &= \tilde{a} / \|\tilde{a}\|_2, \\ H_a \tilde{v} &= Q^T a, & H_a &= \sum_j N_j (a^T g_j)^2 U_j^T U_j + \lambda \text{Id}_d, & v &= \tilde{v} / \|\tilde{v}\|_2. \end{aligned}$$

Первая система мала ($m \times m$). Вторую можно решать через действия

$$H_a x = \sum_j N_j (a^T g_j)^2 U_j^T (U_j x) + \lambda x :$$

плотную матрицу размера $d \times d$ строить необязательно. Эквивалентно можно решать регуляризованную задачу наименьших квадратов

$$\min_x \sum_j N_j \|e_j - (a^T g_j) U_j x\|_2^2 + \lambda \|x - (P - B)^T a\|_2^2.$$

Попеременные шаги улучшают пару с учётом различной чувствительности локальных операторов. Остановить поиск при стабилизации направлений (например, малости $1 - |v_{t+1}^T v_t|$) или достижении лимита; контролировать также невязки систем. Нулевые $\tilde{a}$ или $\tilde{v}$ не нормировать: прекратить попытку либо выбрать другое начало.

3. Точный масштаб и принятие компоненты. Для найденной пары вычислить

$$R_B(a, v) = a^T Q(B) v, \quad D(a, v) = \sum_j N_j (a^T g_j)^2 \|U_j v\|_2^2 + \lambda, \quad \sigma_* = \frac{R_B(a, v)}{D(a, v)}.$$

Поскольку $F(B + \sigma a v^T) - F(B) = D \sigma^2 - 2 R_B \sigma$, это точный минимум по масштабу; ожидаемое уменьшение равно $\gamma = R_B^2 / D$. Проверить фактическое уменьшение исходного

F , затем добавить $\sigma_* a v^\top$. Знак масштаба можно перенести в a . При слишком малом улучшении завершить построение либо проверить другое начало.

4. Сжатие и совместная переоценка. Записать накопленную матрицу как $LR^\top$, заполнить сокращённые QR-разложения $L = Q_L R_L$, $R = Q_R R_R$ и малое SVD $R_L R_R^\top = \hat{A} \Sigma \hat{V}^\top$. Тогда

$$B = A \Sigma V^\top, \quad A = Q_L \hat{A}, \quad V = Q_R \hat{V}, \quad A^\top A = V^\top V = \text{Id}_s,$$

где $s \leq k$ — число ненулевых компонент. Это устраняет зависимые факторы без изменения матрицы. Удаление ненулевых малых сингулярных значений уже меняет B и требует отдельной проверки F . Для фиксированных столбцов a_ℓ, v_ℓ совместно уточнить масштабы:

$$\begin{aligned} M_{\ell t} &= \sum_j N_j (a_\ell^\top g_j) (a_t^\top g_j) (U_j v_\ell)^\top (U_j v_t) + \lambda \delta_{\ell t}, \\ h_\ell &= \sum_j N_j (a_\ell^\top g_j) I_j^\top U_j v_\ell + \lambda a_\ell^\top P v_\ell, \quad M \sigma = h. \end{aligned}$$

Положить $B_k = \sum_{\ell=1}^s \sigma_\ell a_\ell v_\ell^\top$. Малая система учитывает взаимодействие всех уже выбранных компонент и даёт точный минимум в их линейной оболочке; при $\lambda > 0$ она положительно определена. Коэффициенты σ_ℓ могут иметь любой знак.

5. Остановка и результат. Повторять шаги 1–4 до r добавок или малости относительно улучшения $\gamma / \max(1, F(B_{k-1}))$; сохранять итоговую B , значение F и причину остановки. Попеременный поиск не гарантирует глобального минимума: малое улучшение найденной пары не исключает более полезных направлений. Для следующего внешнего шага ADP извлекают ортонормированный базис строк B . При $\text{rank}(B) < m$ недостающие направления дополняют из P после проекции на дополнение к найденному пространству; эти направления не восстановлены самой B . Если $B = T \hat{P}$ имеет полный ранг строк, то переход к $\hat{P} \hat{P}^\top = \text{Id}_m$ сохраняет предсказания при замене $g_j \mapsto T^\top g_j$. Ортонормирование не обязано сохранять штраф в F .

Вариант малоранговой поправки. Для ограничения $\text{rank}(\Delta) \leq r$, $B = P + \Delta$, применить ту же схему к Δ , начиная с $\Delta_0 = 0$, с заменами $I_j \mapsto I_j - U_j P^\top g_j$ и регуляризационной цели $P \mapsto 0$. Вернуть $B = P + \Delta$: малый ранг здесь относится к изменению базиса, а полный ранг B необходимо проверять отдельно.

Отличие от текущей реализации (SVD_cur.tex). При стандартном штрафе Фробениуса математическая схема совпадает; SVD.py конкретизирует её вычислительные шаги. Функция solve сама оценивает g_j на входном базисе и фиксирует их до завершения жадного построения, а затем повторно оценивает на итоговом базисе. Начальное v выбирается по ведущей компоненте $Q - (QV)V^\top$, то есть вне уже найденного правого пространства; дальнейший поиск не ограничивается этим дополнением. Условные системы решаются Холецким или LSMR с проверкой нормальной невязки и, при необходимости, уточнением; используются кэш $U_j V$, проверки численного ранга и отсутствия роста функционала. Реализация требует $r < m$, допускает $\lambda = 0$ и возвращает ортонормированный базис с диагностикой (отдельный solve_fixed_coefficients возвращает сырую B). Опциональная спектральная метрика меняет регуляризационный штраф и реализуется преобразованием координат; в изложенной выше базовой схеме она не включена.