

Разделимые модели и простые повороты

Единая теория SVD, EDR/ADE и анизотропной адаптации

Исследовательская записка по материалам SVD/

1 октября 2026 г.

Аннотация

Общая конструкция состоит из трёх операций: исключить линейные локальные коэффициенты, представить искомую структуру малыми координатами и вычислять только действия соответствующих операторов. SVD является точным решением при разделимой квадратичной метрике, либо разложением касательного шага на независимые плоские повороты. Матричные поправки, Grassmann-обновления, CP/Tucker-поля и спектральный локализатор получают место в одной схеме, с отдельными условиями точности. Выведены способы сокращения вычислений: профилированный поиск угла со скалярной стоимостью, общий малый core, адаптивный ранг касательного шага и сжатие статистик без изменения цели.

Содержание

1 Наблюдаемая модель и четыре различных метрики	2
2 Общая конструкция: профиль, координаты, действия	2
3 SVD-решатель как аффинный частный случай	3
4 Профилирование и геометрия подпространства	5
5 Улучшение I: профильный поиск угла и ранга шага	6
6 Улучшение II: кривизна, core и точное сжатие	8
7 Улучшение III: пространственное поле и Tucker в касательных координатах	9
8 Анизотропия и связь ADE, OPG, ADP, MAVE	11
9 Практическая программа и границы результата	12
A Карта исходных идей и исправлений	13
B Научные предшественники и пределы обобщения	14

Статус утверждений. Формулы с доказательством ниже — следствия указанных моделей. Научные предшественники отмечены ссылками. Предлагаемые варианты обозначены явно; качество восстановления и время полного алгоритма для них не измерены. Узкий замер вычисления углов приведён в разделе 5. Исходные математические

ошибки исправлены, а несовместимые цели представлены разными частными случаями.

1 Наблюдаемая модель и четыре различных метрики

Пусть $x_i \in \mathbb{R}^d$, $y_i = f(x_i) + \varepsilon_i$ и в глобальной multi-index модели $f(x) = \psi(Y_*^\top x)$, $Y_* \in \mathbb{R}^{d \times m}$, $Y_*^\top Y_* = I_m$. Тогда $\nabla f(x) = Y_* \nabla \psi(Y_*^\top x)$. При $\mathbb{E}[\nabla \psi \nabla \psi^\top] \succ 0$ пространство градиентов совпадает с EDR-пространством. Один средний градиент может обнулиться; для $m > 1$ нужна семья производных или их внешние произведения. Структурная адаптация ADE непосредственно предшествует этой постановке [1]; исходная MAVE использует локальные регрессии [2].

Для центра x_j , $j = 1, \dots, J$, положим

$$w_{ij} = K(h^{-2}(x_i - x_j)^\top D_j(x_i - x_j)), \quad N_j = \sum_i w_{ij} > 0, \quad (1)$$

$$\begin{aligned} \bar{x}_j &= N_j^{-1} \sum_i w_{ij} x_i, & z_{ij} &= x_i - \bar{x}_j, \\ \Sigma_j &= N_j^{-1} \sum_i w_{ij} z_{ij} z_{ij}^\top, & c_j &= N_j^{-1} \sum_i w_{ij} z_{ij} y_i. \end{aligned} \quad (2)$$

K получает квадрат расстояния; его определение не меняется при реформулировке. Для матрицы направлений $S_j \in \mathbb{R}^{p \times d}$ ADP-статистики равны $U_j = S_j \Sigma_j \in \mathbb{R}^{p \times d}$, $I_j = S_j c_j \in \mathbb{R}^p$. Локальная модель:

$$I_j \simeq U_j Y_j g_j, \quad g_j \in \mathbb{R}^m. \quad (3)$$

Нормирование на N_j сделано в статистиках; внешний множитель N_j в цели применяется один раз. Множитель $1/4$ исходной TeX-постановки поглощаем в масштабы штрафов; при сравнении реализаций его надо учитывать.

В дальнейшем различаются:

1. D_j — **локализация**: меняет w, I, U и статистический метод;
2. $W_j \succeq 0$ — **метрика невязки**: $\|I_j - U_j Y_j g_j\|_{W_j}^2$;
3. $H \succ 0$ — **метрика матричного штрафа**: $\|(B - P)H^{1/2}\|_F^2$;
4. $M_Y \succ 0$ на касательном пространстве — **метрика шага/предобусловливание**: меняет направление поиска.

Выбор другой геометрии оптимизатора с проверкой той же цели может сохранять оценщик. Изменение первых трёх объектов обычно меняет его. Для вывода ниже W_j включаем в U_j, I_j через $W_j^{1/2}$; при базовом finite-sketch ADP $W_j = I_p$.

2 Общая конструкция: профиль, координаты, действия

Параметр θ задаёт структуру: матрицу, подпространство, поле подпространств или анизотропный PSD-тензор. Локальный словарь $\Psi_j(\theta) \in \mathbb{R}^{p \times k}$ и линейные коэффициенты c дают класс

$$\Phi(\theta) = \min_c \{ \|b - A(\theta)c\|^2 + \|\mathcal{R}(\theta)c\|^2 \} + \Omega(\theta). \quad (4)$$

Здесь блоки $b_j = \sqrt{N_j} I_j$, $A_j c = \sqrt{N_j} \Psi_j(\theta) c_j$; $\mathcal{R}$ может задавать ridge или связь между центрами. Это разделимая нелинейная МНК, исключение линейных переменных — variable projection [3]. Если коэффициенты фиксированы, минимум отсутствует: получается другая, условная задача той же операторной схемы.

Утверждение 2.1 (Условия корректного профиля). Пусть расширенный дизайн $\tilde{\mathcal{A}} = [\mathcal{A}; \mathcal{R}]$ имеет локально постоянный ранг; при полном столбцовом ранге $c_* = (\tilde{\mathcal{A}}^\top \tilde{\mathcal{A}})^{-1} \tilde{\mathcal{A}}^\top \tilde{b}$, $\tilde{b} = [b; 0]$, а

$$\Phi = \|\tilde{b}\|^2 - \tilde{b}^\top \tilde{\mathcal{A}} (\tilde{\mathcal{A}}^\top \tilde{\mathcal{A}})^{-1} \tilde{\mathcal{A}}^\top \tilde{b} + \Omega.$$

Если при замене представителя $\theta \mapsto \theta \cdot Q$ словарь преобразуется как $\Psi_j(\theta \cdot Q) = \Psi_j(\theta) \rho(Q)$, а штрафы сохраняются при $c_j \mapsto \rho(Q)^{-1} c_j$, профиль зависит только от класса эквивалентности $[\theta]$.

Доказательство. Первая формула — результат исключения коэффициентов из квадратичной формы. Для второй замена коэффициентов взаимно однозначна и сохраняет каждое значение минимизируемого выражения. Формулы с обратными матрицами описывают алгебру; вычислять следует QR/SVD или расширенную МНК. $\square$

Упрощение структуры. В текущей точке выбираем малое линейное пространство $\mathcal{E}(\alpha) = \sum_{\ell=1}^s \alpha_\ell E_\ell$. Новая структура получается через

$$\theta_+(\alpha) = \chi_\theta(\mathcal{E}(\alpha)), \quad \min_\alpha \Phi(\theta_+(\alpha)). \quad (5)$$

χ — аффинное отображение для матриц, экспонента/ретракция для подпространств, покомпонентное отображение для поля. На произвольном гладком многообразии это локальная схема с Taylor-моделью; глобальное разложение на коммутирующие повороты существует в специальных геометриях, в частности на Grassmann. Универсальной дешёвой глобальной линеаризации произвольного многообразия из этой конструкции не следует.

В линейной условной задаче профиль по α — точная малая МНК. В нелинейной задаче Jacobian $\mathcal{J}\mathcal{E}$ даёт малую модель Gauss–Newton/trust region. Малый core удешевляет повторные шаги; построение самого пространства и проекций может оставаться дорогим.

3 SVD-решатель как аффинный частный случай

Сохраним строковую нотацию живого solver: $B, P \in \mathbb{R}^{m \times d}$, $PP^\top = I_m$, $Y_0 = P^\top$. При фиксированных g_j :

$$F(B) = \sum_j N_j \|I_j - U_j B^\top g_j\|^2 + \lambda \|(B - P)H^{1/2}\|_F^2. \quad (6)$$

Нужно явно выбрать $\text{rank}(B) \leq r$ либо $\text{rank}(B - P) \leq r$. При $H = I$, $\lambda > 0$ определим

$$(AB)_j = \sqrt{N_j} U_j B^\top g_j, \quad \mathcal{A}^* e = \sum_j \sqrt{N_j} g_j (U_j^\top e_j)^\top, \quad (7)$$

$$\mathcal{L}X = \sum_j N_j g_j g_j^\top X U_j^\top U_j + \lambda X, \quad C = \sum_j N_j g_j I_j^\top U_j + \lambda P. \quad (8)$$

$F = \text{const} - 2\langle C, B \rangle_F + \langle B, \mathcal{L}B \rangle_F$; $\nabla F = 2(\mathcal{L}B - C)$. Нормальный оператор положительно определён, но его явная сборка не нужна:

$$\text{vec}(\mathcal{L}X) = \left[\sum_j N_j (U_j^\top U_j) \otimes (g_j g_j^\top) + \lambda I_{md} \right] \text{vec } X.$$

Использована столбцовая вес. **Все перекрёстные блоки по компонентам g_j сохраняются.** Решать строки B независимо допустимо лишь при дополнительных условиях делимости, а не вследствие малого m .

3.1 Атомы и точный выигрыш

При произвольном SPD- H точная замена $\tilde{B} = BH^{1/2}$, $\tilde{P} = PH^{1/2}$, $\tilde{U}_j = U_jH^{-1/2}$ приводит (6) к Frobenius penalty и сохраняет оба rank constraints. Это объясняет optional metric-whitening живого solver. Выбор самого H меняет штраф; преобразование координат при уже выбранном H математически точно. Внутренний $\tilde{P}$ обычно не ортонормирован: итоговый basis извлекается после возврата в исходные координаты.

Для $E = av^\top$, $\|a\| = \|v\| = 1$, $Q = C - \mathcal{L}B$, положим

$$R = \langle Q, E \rangle_F, \quad D = \langle E, \mathcal{L}E \rangle_F = \sum_j N_j (g_j^\top a)^2 \|U_j v\|^2 + \lambda. \quad (9)$$

Тогда $F(B + tE) = F(B) - 2tR + t^2D$, и при $D > 0$

$$t_* = R/D, \quad F(B) - F(B + t_*E) = R^2/D. \quad (10)$$

Это точный поиск длины шага для выбранного атома, но не доказательство оптимальности пары (a, v) . SVD градиента максимизирует числитель при евклидовой нормировке; переменный знаменатель может изменить лучший атом. Жадный SVD имеет близкого предшественника в rank-one matrix pursuit [9]; гарантии для matrix completion не переносим на ADP.

Для зафиксированных атомов E_ℓ общий refit масштабов решает $K\alpha = h$, где $K_{\ell t} = \langle E_\ell, \mathcal{L}E_t \rangle_F$, $h_\ell = \langle C - \mathcal{L}B_0, E_\ell \rangle_F$ при $B = B_0 + \sum \alpha_\ell E_\ell$. QR факторов и SVD малого произведения меняют представление, сохраняя матрицу точно, если не усекать ранг.

3.2 Когда одного SVD достаточно

Теорема 3.1 (Разделимая квадратичная метрика). *Если полный оператор, включая штраф, имеет вид $\mathcal{L}X = GXH$, $G \succ 0$, $H \succ 0$, то*

$$B_r = G^{-1/2} [G^{-1/2}CH^{-1/2}]_r H^{-1/2} \quad (11)$$

глобально минимизирует F при $\text{rank}(B) \leq r$. Для $\text{rank}(B - P) \leq r$ та же формула применяется к $\Delta = B - P$ с $C_\Delta = C - \mathcal{L}P$.

Доказательство. При $Z = G^{1/2}BH^{1/2}$ квадратичная часть равна $\|Z - G^{-1/2}CH^{-1/2}\|_F^2$ с точностью до константы. Обратимые левые и правые множители сохраняют ранг; применяется теорема Эккарта–Янга [13]. Разность с полным минимумом равна сумме квадратов отброшенных сингулярных значений преобразованной матрицы. $\square$

Исходная изотропная модель $U_j^\top U_j = \eta_j I_d$, $H = I$ даёт $G = \sum_j N_j \eta_j g_j g_j^\top + \lambda I_m$. Общий случай — сумма произведений Кронекера; даже $U_j^\top U_j = \eta_j H_0$ с обычным ridge λX в общем случае не даёт одного GXH_0 . Произвольное whitening в md -мерной vectorized задаче обычно не сохраняет матричный ранг. Взвешенная малоранговая аппроксимация потому требует иной оптимизации [6, 7], а не обычного усечения SVD полного решения.

3.3 Полный core и ограничения ранга

Более богатые малые координаты:

$$B = B_0 + AMV^\top, \quad A^\top A = V^\top V = I_r, \quad M \in \mathbb{R}^{r \times r}. \quad (12)$$

При фиксированных A, V это расширенная МНК на r^2 неизвестных: локальный дизайн применяет $\sqrt{N_j}(U_j V)M^\top(A^\top g_j)$, ridge-цель core равна $A^\top(P - B_0)V$ при $H = I$. Диагональный M восстанавливает refit масштабов исходного SVD. Свободный M не ухудшает

условный минимум, но требует больше работы; последующая оптимизация A, V остаётся невыпуклой [7].

При $r < m$, $\text{rank}(B) \leq r$ принципиально не задаёт полный m -базис:

$$\min_{\text{rank}(B) \leq r} \|B - P\|_F^2 = m - r. \quad (13)$$

Следовательно $F(B) \geq \lambda(m-r)$ при $H = I$. Недостающие направления после дополнения из P определяются prior. Для $B = P + \Delta$ с $\|\Delta\|_2 < 1$ полный row rank сохраняется, и

$$d_{\text{ch}}(\text{span}(B^T), \text{span}(P^T)) \leq \frac{\|\Delta\|_F}{1 - \|\Delta\|_2}. \quad (14)$$

Действительно, $\sigma_{\min}(B) \geq 1 - \|\Delta\|_2$, а ортогональная компонента ортонормированного B^T ограничена $\|\Delta^T(BB^T)^{-1/2}\|_F$. Это контроль изменения относительно prior, а не качества относительно неизвестного Y_* .

4 Профилирование и геометрия подпространства

Для фиксированных I, U, N определим

$$\begin{aligned} \Phi(Y) &= \sum_j N_j \min_g \{ \|I_j - U_j Y g\|^2 + \tau \|g\|^2 \} + \lambda d_{\text{ch}}^2(Y, Y_0), \\ d_{\text{ch}}^2(Y, Y_0) &= m - \|Y_0^T Y\|_F^2, \quad Y^T Y = I_m. \end{aligned} \quad (15)$$

Подстановка $Y \mapsto YQ$, $g \mapsto Q^T g$, $Q \in O(m)$, показывает инвариантность. Поэтому $[Y] \in \text{Gr}(m, d)$. Для $M_j = U_j Y$, $A_j = M_j^T M_j + \tau I$:

$$A_j g_j = M_j^T I_j, \quad \Phi = \sum_j N_j (\|I_j\|^2 - I_j^T M_j g_j) + \lambda d_{\text{ch}}^2. \quad (16)$$

При $\tau > 0$ профиль гладкий, даже если M_j теряет ранг. При $\tau = 0$ применимы производные на области постоянного ранга; cutoff псевдообратной требует отдельной обработки переходов. Условия гладкости VARPRO обсуждаются в [3].

При $\tau = 0$ и отсутствии basis penalty свободная полноранговая матрица и её ортонормированный базис дают один профиль благодаря $GL(m)$ -замене коэффициентов. При $\tau > 0$ штраф $\|g\|^2$ имеет этот смысл только в ортонормированном представителе; свободное масштабирование базиса меняет его. Fixed- g задача (6) и её Frobenius penalty потому не тождественны (15). Замена на $\tau > 0$ или chordal penalty — вариант оценивателя, а не скрытое численное ускорение.

Пусть $r_j = I_j - M_j g_j$. По условию оптимальности локальных коэффициентов и теореме об огибающей:

$$G = \text{grad } \Phi(Y) = (I - Y Y^T) \left[-2 \sum_j N_j U_j^T r_j g_j^T - 2 \lambda Y_0 Y_0^T Y \right]. \quad (17)$$

Ортопроектор реализуется как $X - Y(Y^T X)$, без плотной $d \times d$ матрицы. Ортонормированные представления и Grassmann-геодезические исследованы в [4]; profiled rank-one subspace tracking — в GROUSE [5]. Здесь каждый U_j — общий оператор наблюдения, а не только выборка координат GROUSE.

4.1 Искомое разложение на простые повороты

Здесь предполагается $0 < m < d$; при $m = d$ подпространство единственно и ненулевых горизонтальных поворотов нет. Горизонтальный касательный шаг Z удовлетворяет $Y^T Z = 0$. Его компакт SVD $Z = V \Theta A^T$ имеет ранг $q \leq \min(m, d - m)$ и $V^T V = A^T A = I_q$. Для выбранного ортонормированного представителя экспонента равна

$$\text{Exp}_Y(Z) = Y(I - AA^T) + Y A \cos \Theta A^T + V \sin \Theta A^T. \quad (18)$$

Это одновременно q поворотов пар $(Y a_\ell, v_\ell)$. Генераторы $v_\ell(Y a_\ell)^T - (Y a_\ell)v_\ell^T$ действуют в взаимно ортогональных плоскостях и коммутируют. Так получается точное разложение *одного* геодезического шага; направления, переоцененные после каждого поворота, обычно уже не коммутируют.

При $q = 1$:

$$Y(t) = Y + (Y a(\cos t - 1) + v \sin t) a^T, \quad Y^T v = 0, \quad \|a\| = \|v\| = 1. \quad (19)$$

В частности, $\text{rank}(Y(t) - Y) \leq 1$, хотя $\text{rank} Y(t) = m$. При общем q разность в (18) имеет ранг не выше q . Это *точная связь* поворотов с малоранговыми поправками базиса. Обратная связь условна: произвольная ambient-поправка может содержать масштабирование и смену координат. Если она горизонтальна, её QR-образ является геометрическим шагом; fixed- g цели всё равно различаются.

4.2 Экспонента, графовая карта и другие ретракции

Polar-представитель $R_Y(Z) = (Y + Z)(I + Z^T Z)^{-1/2}$ задаёт то же подпространство, что $\text{qf}(Y + Z)$, и имеет углы $\arctan \theta_\ell$. При $Z = V \Theta A^T$ семейство $\text{Exp}_Y(V \varphi(\Theta) A^T)$ — локальная ретракция, если $\varphi(0) = 0$, $\varphi'(0) = 1$; условие $\varphi''(0) = 0$ даёт второй порядок. Нужна достаточная гладкость матричного отображения. Экспоненте соответствует $\varphi(t) = t$, polar — $\arctan t$, ортогональному Cayley на этих плоскостях — $2 \arctan(t/2)$. Общая теория projection-like retractions: [8].

Все три совпадают до второго порядка в координатах подпространства:

$$\text{Exp}_Y(Z) = Y + Z - \frac{1}{2} Y Z^T Z + O(\|Z\|_F^3). \quad (20)$$

Это поправка на кривизну. QR-базис может отличаться вертикальной ротацией; равенство Taylor-представителей надо понимать с согласованным gauge. Для rank-one polar описывает угол $\arctan \eta \in (-\pi/2, \pi/2)$: граничная ортогональная линия достигается лишь в пределе $|\eta| \rightarrow \infty$. Ни одна такая карта не является единственной глобальной картой Gr.

5 Улучшение I: профильный поиск угла и ранга шага

5.1 Угол: линейная алгебра один раз, скаляры многократно

Для rank-one $Y(t)$ выберем $A_\perp \in \mathbb{R}^{m \times (m-1)}$, $[A_\perp, a] \in O(m)$, и обозначим

$$C_j = U_j Y A_\perp, \quad u_j = U_j Y a, \quad v_j = U_j v, \quad q_j(t) = u_j \cos t + v_j \sin t.$$

Локальный дизайн состоит из постоянных столбцов C_j и одного $q_j(t)$. При $\tau > 0$ положим

$$\Pi_j = I - C_j(C_j^T C_j + \tau I)^{-1} C_j^T. \quad (21)$$

Π_j симметрична положительно определена, но при $\tau > 0$ не является ортопроектором. Искключение постоянных коэффициентов через дополнение Шура даёт

$$\min_g \{ \|I_j - U_j Y(t) g\|^2 + \tau \|g\|^2 \} = k_j - \frac{(b_j \cos t + c'_j \sin t)^2}{a_j \cos^2 t + 2d_j \sin t \cos t + e_j \sin^2 t + \tau}, \quad (22)$$

где $k_j = I_j^\top \Pi_j I_j$, $b_j = u_j^\top \Pi_j I_j$, $c'_j = v_j^\top \Pi_j I_j$, $a_j = u_j^\top \Pi_j u_j$, $d_j = u_j^\top \Pi_j v_j$, $e_j = v_j^\top \Pi_j v_j$.

Доказательство. После минимизации по $m - 1$ коэффициентам остаётся $(I_j - q_j \gamma)^\top \Pi_j (I_j - q_j \gamma) + \tau \gamma^2$. Её скалярный минимум равен $I_j^\top \Pi_j I_j - (q_j^\top \Pi_j I_j)^2 / (q_j^\top \Pi_j q_j + \tau)$. $\square$

При $\tau = 0$ формула сохраняется при невырожденных устранимых системах и положительном знаменателе; вырожденные углы обрабатываются отдельно. Π_j не строится: для $x, y \in \{I_j, u_j, v_j\}$ вычисляется $x^\top y - (C_j^\top x)^\top (C_j^\top C_j + \tau I)^{-1} (C_j^\top y)$. Chordal penalty также определяется малыми произведениями $Y_0^\top Y$, $Y_0^\top v$ и тригонометрией. После подготовки одна оценка угла стоит $O(J)$ и $O(1)$ дополнительной памяти на центр; при $m = 1$ постоянных столбцов нет.

Это **замкнутая формула значения**, а не универсальная замкнутая формула оптимального угла. Сумма рациональных функций может иметь много минимумов. Armijo достаточно для спуска; сетка плюс локальный Brent является эвристикой глобального поиска. Для глобального сертификата нужно ограничение интервала с доказанными bounds либо перечисление всех критических точек. У функции период π в координатах подпространства.

При $q > 1$ следует заранее сохранить только $U_j[Y, V]$. Тогда любой набор углов в (18) оценивается через дизайн на $m + q$ столбцах, без повторного применения U_j к d -векторам. Полная стоимость refit на одну оценку — $O(J(pm^2 + m^3))$; для $q = 1$ (22) сокращает её до $O(J)$.

Узкий численный пример. Для $J = 128$, $p = 40$, $d = 300$, $m = 3$, $\tau = 0.2$ и 61 пробного угла сравнение с пакетным augmented-SVD refit на трёх фиксированных seeds дало отношение времени 0.160–0.167 с учётом общей проекции $U_j[Y, v]$. Для самих оценок угла вместе с подготовкой отношение равно 0.032–0.042; относительное расхождение кривых менее $1.7 \cdot 10^{-16}$. Измерение — медиана семи повторов после прогрева, один BLAS thread. Это ускорение вычисления одной frozen-curve; выбор направления, минимизация угла, внешние шаги и восстановление EDR не измерялись. Исходники, времена и ограничения памяти: `angle_results.json` и `REPORT.md` в каталоге проверок.

5.2 Спектральный бюджет вместо фиксированной жадности

Если $G = V \operatorname{diag}(s_\ell) A^\top$, то задача

$$\min_{Y^\top Z=0, \operatorname{rank} Z \leq q, \|Z\|_F \leq 1} \langle G, Z \rangle_F$$

имеет решение $Z = -[G]_q / \|[G]_q\|_F$ при ненулевом числителе. Доказательство: неравенство фон Неймана и Коши–Буняковского; достижение — на первых q сингулярных компонентах. Практический выбор:

$$\sum_{\ell \leq q} s_\ell^2 \geq (1 - \epsilon) \|G\|_F^2. \quad (23)$$

Он контролирует долю *первопорядковой энергии*, не ошибку EDR. В ядерном единичном шаре оптимален один ведущий атом; в операторном шаре — $-V A^\top$ по ненулевым singular directions. Различные нормы дают разные семейства спусков, без основания считать одно универсально лучшим.

Утверждение 5.1 (Ограниченная гарантия спуска). Пусть профиль гладок и его вторая производная вдоль единичных геодезических не превосходит $L > 0$. Для $Z = -[G]_q / \|[G]_q\|_F$ и $t = \|[G]_q\|_F / L$

$$\Phi(Y) - \Phi(\text{Exp}_Y(tZ)) \geq \|[G]_q\|_F^2 / (2L).$$

При $q = 1$ это не меньше $\|G\|_F^2 / (2L \min(m, d - m))$.

Доказательство. Taylor-bound равен $t\langle G, Z \rangle_F + Lt^2/2$. Подставляем шаг; для rank-one используем

$$s_1^2 \geq \frac{\|G\|_F^2}{\min(m, d - m)}.$$

□

На компактном Gr при $\tau > 0$ и фиксированных конечных статистиках можно выбрать конечное L . Повторные такие шаги дают $\|G_k\|_F \rightarrow 0$. Armijo со стандартными условиями также даёт достаточный спуск. Сходимость всей последовательности к одной точке и глобальный минимум из одной этой оценки не следуют. При изменении h, D, S меняется сама цель; гарантия относится только к внутреннему frozen-statistics решению.

6 Улучшение II: кривизна, core и точное сжатие

6.1 Полный профильный Jacobian

Для горизонтального Z и $T_j = U_j Z$ дифференцирование локальной системы (16) даёт

$$A_j \dot{g}_j = T_j^\top r_j - M_j^\top T_j g_j, \quad \dot{r}_j = \begin{bmatrix} -T_j g_j - M_j \dot{g}_j \\ -\sqrt{\tau} \dot{g}_j \end{bmatrix}, \quad \tilde{r}_j = \begin{bmatrix} r_j \\ -\sqrt{\tau} g_j \end{bmatrix}. \quad (24)$$

Все величины относятся к выбранному гладкому gauge. Однозначный $\dot{g}_j$ эта система задаёт при $\tau > 0$ либо полным столбцовом ранге M_j . При $\tau = 0$ и постоянном недостаточном ранге нужна полная производная псевдообратной; решение одной сингулярной нормальной системы её не заменяет. Вторая часть профиля может быть представлена невязкой $\sqrt{\lambda}(I - Y_0 Y_0^\top)Y$, её производная — $\sqrt{\lambda}(I - Y_0 Y_0^\top)Z$. В совместный residual включаются блоки $\sqrt{N_j} \tilde{r}_j$, а в $\mathcal{J}$ — $\sqrt{N_j} \dot{r}_j$; блок близости добавляется с уже указанным $\sqrt{\lambda}$. Этот взвешенный Jacobian используется в расширенной МНК:

$$\min_{\alpha} \|\tilde{r} + \mathcal{J}\mathcal{E}(\alpha)\|^2 + \mu \|\alpha\|^2, \quad \mu > 0. \quad (25)$$

Ретракция и проверка исходного Φ обязательны. GN не равен точному Riemannian Hessian: остаются остаточные second-derivative terms и геометрическая кривизна. Если отбросить в $\dot{g}_j$ член $T_j^\top r_j$, получится дополнительная аппроксимация, уместность которой зависит от величины невязки. Полное (24) не требует независимого разложения по строкам индекса.

6.2 Разделимые аппроксимации оператора

Для матричной задачи можно искать $\mathcal{L}_0 X = GXH$ либо $\sum_{\ell=1}^s G_\ell X H_\ell$. Перестановка индексов превращает приближение одним произведением Кронекера в rank-one approximation [10]. Но собирать $(md)^2$ элементов ради этой операции невыгодно; нужны действия, малые projected blocks либо аналитическая структура. Неограниченное SVD-приближение не гарантирует SPD факторов.

Если проверено $\mathcal{L}_0 \succ 0$ и

$$\rho = \|\mathcal{L}_0^{-1/2}(\mathcal{L} - \mathcal{L}_0)\mathcal{L}_0^{-1/2}\|_2 < 1, \quad (26)$$

то $(1 - \rho)\mathcal{L}_0 \preceq \mathcal{L} \preceq (1 + \rho)\mathcal{L}_0$; condition number предобусловленной системы не больше $(1 + \rho)/(1 - \rho)$. Это следствие Rayleigh quotient. Небольшой случайный набор probes не доказывает (26) для всех направлений. Без оценки ρ surrogate-SVD — инициализация, затем проверяется истинный функционал и residual. Использование $\mathcal{L}_0$ как предобусловливателя сохраняет цель; замена целевого оператора на $\mathcal{L}_0$ её меняет.

Полный условный минимум B_* удовлетворяет $\mathcal{L}B_* = C$. При $\mathcal{L} \succeq \lambda I$, $\lambda > 0$:

$$\|B - B_*\|_F \leq \|\mathcal{L}B - C\|_F / \lambda, \quad F(B) - F(B_*) \leq \|\mathcal{L}B - C\|_F^2 / \lambda. \quad (27)$$

Это сертификат *неограниченного* условного решения, не оптимума rank- r или profiled задачи. Для приближённой поправки D с $s = \mathcal{L}D - Q$:

$$F(B + D) - F(B) = -\langle D, \mathcal{L}D \rangle_F + 2\langle D, s \rangle_F.$$

Условие $2|\langle D, s \rangle_F| < \langle D, \mathcal{L}D \rangle_F$ достаточно для спуска. Оно позволяет согласовывать Krylov tolerance с реальным шагом. При $\lambda = 0$ универсальных bounds (27) нет.

6.3 Сжатие, сохраняющее finite-sketch цель

Если $[U_j, I_j] = Q_j R_j$ — тонкое QR без rank truncation, то $\|I_j - U_j Y g\| = \|\bar{I}_j - \bar{U}_j Y g\|$, где $[\bar{U}_j, \bar{I}_j] = R_j$. Число строк уменьшается до $\min(p, d + 1)$; выигрыш возможен при $p > d + 1$. Нормировки и threshold rules сохраняются. Усечение численного ранга — отдельная аппроксимация. Если доступна точная факторизация $U_j = Q_j R_j$, предпочтительны действия факторов вместо хранения Jpd элементов. Разложение шумового оператора с усечением не является точным само по себе.

Кэши $U_j V$, $U_j Y$ и QR/GN workspace допустимы лишь при фиксированных статистиках и basis-dependent ключе. После обновления ядра или направлений кэш пересчитывается. Coarse-space/SVD направления могут использоваться для warm start и дефляции в расширенном LSMR, сохраняя исходный residual и оба блока ridge. Дополнение полного решения вне coarse-space не обязано сохранять прежний rank bound. Случайный SVD уместен при дорогих действиях и большом спектральном блоке; при малом m нужен выигрыш в числе проходов, а не только меньший размер факторизации. Ядерный штраф $F(B) + \gamma \|B\|_*$ задаёт выпуклый вариант, но не эквивалентен жёсткому ограничению ранга.

7 Улучшение III: пространственное поле и Tucker в касательных координатах

Замена Y на Y_j сама по себе даёт J независимых локальных моделей. Для скалярного отклика один центр наблюдает лишь вектор $Y_j g_j$; локальное $m > 1$ пространство без совместной информации не идентифицируется. Поле надо связывать через пространственный словарь, граф или общую оболочку. Кроме того, поле регрессионных EDR-плоскостей не обязано быть касательным полем многообразия носителя x : последняя модель имеет другие предположения [12]. Для интегрируемости распределения плоскостей нужны дополнительные условия, например инволютивность по Фробениусу.

7.1 Линейное поле и его геометрические ограничения

В строковой нотации CP/Tucker [11] дают

$$B_j = \sum_{\ell=1}^s w_{j\ell} a_\ell v_\ell^\top \quad (\text{CP}), \quad (28)$$

$$B_j = A \left(\sum_{\ell=1}^s w_{j\ell} M_\ell \right) V^\top \quad (\text{Tucker}). \quad (29)$$

При $s = 1$, $w_{j1} = 1$ и диагональном core получаем общий SVD-index; добавление P_j даёт correction-вариант. Для фиксированных g, A, V, w общий core решается малой расширенной МНК; нельзя независимо решать slices, если они имеют общие неизвестные. Штраф близости имеет *положительный* знак $+\lambda\|B - P\|^2$. Отрицательный знак из черновика не является регуляризацией и может сделать функцию неограниченной снизу. Если $V \in \mathbb{R}^{d \times R}$ и $\text{rank } B_j = m = R$, все row spaces равны $\text{span } V$. Для настоящего вращения полноразмерных локальных m -плоскостей внутри общей оболочки необходимо $R > m$. Например $Y_j = VC_j$, $V^\top V = I_R$, $C_j^\top C_j = I_m$, с $[C_j] \in \text{Gr}(m, R)$; это профилированная reduced-ambient модель. Ограничение $R < d$ вносит approximation bias, если поле выходит за оболочку.

Low-rank третья мода сама по себе не даёт пространственной гладкости. Нужны $w_{j\ell} = w_\ell(x_j)$ с заданной регулярностью либо, например, $\text{tr}(w^\top L_{\text{graph}} w)$; несвязный граф не связывает компоненты. Штраф на различия basis-матриц требует общего gauge; invariant-вариант: $\sum_{(i,j)} \omega_{ij} d_{\text{ch}}^2(Y_i, Y_j)$.

7.2 Геометрически корректное поле малоранговых шагов

В одной локальной карте около Y_0 выберем $V \in \mathbb{R}^{d \times q}$, $Y_0^\top V = 0$, $V^\top V = I_q$, $A \in \mathbb{R}^{m \times k}$, $A^\top A = I_k$ и зададим

$$Z_j = V \left(\sum_{\ell=1}^s w_\ell(x_j) M_\ell \right) A^\top, \quad Y_j = R_{Y_0}(Z_j), \quad M_\ell \in \mathbb{R}^{q \times k}. \quad (30)$$

Это Tucker-параметризация *касательного поля*, после которой ретракция сохраняет $Y_j^\top Y_j = I_m$. Именно Z_j , а не произвольный basis tensor, имеет малый Tucker rank; нелинейное отображение в общем случае не сохраняет этот rank для массива Y_j . При $s = 1$ получается общий rank-min(q, k) геометрический шаг; при $q = k = 1$ — поле простых поворотов. Оболочка $[Y_0, V]$ имеет размер $m + q$, позволяя m -плоскостям меняться.

Хранение параметров — $O(d(m+q) + mk + sqk + Js)$ вместо $O(Jdm)$, если w табулирован; вычисляемый словарь может убрать Js . Предварительные $U_j[Y_0, V]$ стоят $O(Jpd(m+q))$ работы и $O(Jp(m+q))$ памяти; их можно вычислять блоками. После этого все локальные профили используют лишь малую оболочку. При фиксированном словаре и directions GN по M_ℓ — задача на sqk переменных с общим Jacobian; истинный профиль остаётся нелинейным. Для большого поля одна карта может не подходить: нужны перекрывающиеся карты и согласованный перенос/gauge, а не рост коэффициентов до бесконечности. Параметризация без basis-свободы улучшает представление, но сама по себе не доказывает статистическую идентифицируемость поля.

8 Анизотропия и связь ADE, OPG, ADP, MAVE

Для ортонормированного Y и $\Lambda \succeq 0$ две исходные геометрии:

$$D_{\text{full}} = \alpha^2 I + Y \Lambda Y^\top, \quad (31)$$

$$D_{\text{orth}} = \alpha^2 (I - Y Y^\top) + Y \Lambda Y^\top. \quad (32)$$

В (1) масштаб h^{-2} вынесен явно. Они не совпадают вдоль Y : eigenvalues равны $\alpha^2 + \lambda_\ell$ и λ_ℓ соответственно. $D_{\text{orth}} \succ 0$ требует $\alpha > 0$, $\lambda_\ell > 0$; нулевые значения допустимы для PSD-локализации, но не для SPD-whitening. Для $D = \delta I + Y L Y^\top$, L диагональна, любая определённая спектральная функция применяется как

$$f(D)x = f(\delta)x + Y(f(\delta I + L) - f(\delta)I)Y^\top x. \quad (33)$$

Стоимость $O(dm)$, без d^2 хранения. Пара (Y, Λ) естественно задаёт rank- m PSD-структуру $Y \Lambda Y^\top$, с преобразованием $(Y, \Lambda) \mapsto (YQ, Q^\top \Lambda Q)$. Положение подпространства и спектральные масштабы — разные параметры. На границе нулевого спектра меняется ранг и гладкая stratum.

8.1 Какую метрику градиента на самом деле задаёт sketch

Если $\Sigma_j \succ 0$, положим $\hat{v}_j = \Sigma_j^{-1} c_j$. Тогда directional ADP residual равен

$$\|I_j - U_j Y g\|^2 = (\hat{v}_j - Y g)^\top \Sigma_j S_j^\top S_j \Sigma_j (\hat{v}_j - Y g). \quad (34)$$

При $S_j = I$ метрика равна Σ_j^2 . Семейство Σ_j^κ даёт полезную классификацию: $\kappa = 0$ — Euclidean gradient fit/OPG, $\kappa = 1$ — локальная observation-level МНК, $\kappa = 2$ — полный directional moment fit. Действительно, центрированный локальный residual удовлетворяет

$$\sum_i w_{ij} (y_i - \bar{y}_j - z_{ij}^\top Y g)^2 = \text{const}_j + N_j (\hat{v}_j - Y g)^\top \Sigma_j (\hat{v}_j - Y g). \quad (35)$$

Это алгебраическая связь с локальным критерием MAVE [2], при тех же центрах, весах и intercept; её внешний алгоритм и выбор bandwidth не обязаны совпадать с ADP. При $\kappa = 0$, $\tau = 0$ профиль равен $\text{const} - \text{tr}(Y^\top C_{\text{grad}} Y)$, $C_{\text{grad}} = \sum_j N_j \hat{v}_j \hat{v}_j^\top$, и ведущие m eigenvectors дают точный global OPG optimum. Это второй спектральный частный случай общей схемы (4). При вырожденной Σ_j необходимы ограничения на range, псевдообратная либо явная регуляризация; написанный обратный оператор нельзя применять буквально.

Чтобы детерминированно получить $\kappa = 1$ из (34), можно задать $S_j = \Sigma_j^{-1/2}$ в полном локальном пространстве. Это меняет finite-sketch estimator и может дорого стоить. Для ненормированных случайных строк с ковариацией Σ_j^{-1} совпадение метрик имеется лишь в ожидании, с множителем p . Нормирование каждой Gaussian-строки до единичной длины в общем случае нарушает равенство ковариации; текущий anisotropic law не является автоматическим GLS-whitening.

8.2 GLS и информация: необходимые оговорки

При независимом homoskedastic шуме, условно на фиксированных x, w :

$$\text{Cov}(c_j \mid x, w) = \frac{\sigma^2}{N_j^2} \sum_i w_{ij}^2 z_{ij} z_{ij}^\top, \quad \text{Cov}(I_j \mid x, w) = S_j \text{Cov}(c_j) S_j^\top. \quad (36)$$

Отсюда метрика Σ_j не следует автоматически: присутствуют w_{ij}^2 , а окна разных центров могут иметь коррелированный шум. Для $w \in \{0, 1\}$ covariance момента равна $\sigma^2 \Sigma_j / N_j$, что действительно даёт gradient-GLS метрику Σ_j на невырожденном range. Если веса обучены по тем же y , простая условная формула требует дополнительного обоснования. Равенство GN и информации Фишера справедливо для корректной Gaussian likelihood, её ковариационной метрики и идентифицируемого Jacobian; к исходной finite-sketch ADP это без этих условий не относится. Смена κ , local ridge, робастный loss/IRLS или quadratic-jet словарь $\Psi = \text{std} \oplus \text{Sym}^2$ — варианты статистической модели. Последний может уменьшить bias при достаточной гладкости, но добавляет $O(m^2)$ коэффициентов и требует своей проверки variance/идентифицируемости.

9 Практическая программа и границы результата

Конструкция	Что получает алгоритм	Статус изменения
Действия $f(D)$, QR без усечения, компактные факторы	Убирают d^2 tensor или повторный ambient-дизайн	EXACT/NUMERICAL
Общий core M и residual-based tolerances	Не хуже диагонального refit при фиксированных spaces; больше неизвестных	APPROXIMATE, та же fixed- g цель
Профильный rank- q шаг и скалярный поиск угла	Полный rank- m basis; $O(J)$ на угол после подготовки	APPROXIMATE при той же profiled цели; переход с fixed- g /штрафа — ESTIMATOR
Tangent Tucker/общая оболочка	Сокращение числа параметров и дорогих действий, пространственная связь	ESTIMATOR или явная ограниченная модель
OPG $\rightarrow$ MAVE-like metric, GLS, jet/robust loss	Иная статистическая цель; возможен trade-off bias/variance	ESTIMATOR

Предлагаемый основной вариант. Frozen-statistics профиль (15), thin SVD горизонтального градиента, адаптивный q по (23), подготовка $U_j[Y, V]$ и оптимизация углов. Для $q = 1$ применяется (22); при выраженной анизотропии — reduced GN (25) с проверкой истинного Φ . Rank-one разумен при концентрации $s_1^2 / \|G\|_F^2$, дешёвом streaming или ограничении памяти. При малом m полный thin SVD стоит $O(dm^2)$, так что экономия от жадности не гарантирована. Ориентир для поля — (30) с гладким словарём и графовой связью, после успешной проверки глобального случая.

Для dense U базовая память — $O(Jpd)$; работа $U_j Y$ — $O(Jpdm)$, local augmented QR — $O(J(pm^2 + m^3))$, хранение градиента — $O(dm)$. Кэш reduced-design добавляет $O(Jp(m + q))$, при center blocks b — $O(bp(m + q))$. Factorized/streamed U может сократить Jpd , но цену повторных действий надо учитывать. Core-refit может выполняться потоковым QR; плотный $(r^2)^2$ core-Hessian допустим только при явно малом r . GPU помогает batched UV , refit и reductions; переносы, allocation, BLAS threads и число passes остаются частью wall-clock стоимости.

Что уже реализовано. В ADP/solver/SVD.py есть fixed- g matrix/correction targets, greedy rank-one, диагональный refit, отбор SVD-пар по R^2/D , условные direct/LSMR solves и optional penalty whitening. Matrix mode дополняет rank- r результат из prior; correction mode делает QR сырого полного $P + \Delta$, затем local refit. Local ridge τ в этом пути равен нулю. Свободный core, профилированный поиск углов и tangent Tucker здесь теоретические предложения; производственный solver этой запиской не изме-

нён. Убывание сырого F не переносится автоматически через QR, refit и изменение kernel на внешний trace.

Условия научной проверки. Сначала независимые малые reference: forward/adjoint, whitening, profile invariance, gradient/Jacobian, Schur-search, ортонормальность, rank loss, $\tau = 0$, $\lambda = 0$. Затем paired frozen I, U, N с одинаковыми tolerances; далее полные fits на нескольких заранее заданных seeds с отдельным validation набором. Измеряются wall-clock, peak native memory, operator calls/iterations, истинная цель и projector error к Y_* . Objective improvement без eigengap/идентифицируемости и контроля шумового смещения не даёт recovery guarantee. Ранг шага q , размер EDR m , Tucker ranks и envelope R нужно выбирать и измерять отдельно.

А Карта исходных идей и исправлений

Материал	Место в общей конструкции и необходимые уточнения
multiindex.tex, 957–1236, 1274–1579	EDR/local statistics/AO/structural adaptation: разделы 1, 2, 8. Single-index — $m = 1$. Prediction/CV и bandwidth schedule — внешние процедуры, не следствия внутренней geometry.
SVD_solver.tex, 65–817, 833–1135	Оператор, greedy, isotropic SVD, completion, refinement, блоки/GPU: разделы 3, 6, 9. Полный core расширяет diagonal scales; nuclear/random варианты сохраняют отдельные ограничения и статус.
SVD_algorithm.tex; SVD_cur.tex	Алгоритмическая последовательность и live-поведение: разделы 3, 9. Реальные targets, certificate, metric и completion проверены по live-коду; краткие заметки не заменяют его.
grassmann_rank_one.tex, 40–884	Profile/gradient, tangent SVD, exponential/Taylor и greedy rotations: разделы 4, 5. Точное разложение относится к фиксированному шагу, не адаптивной траектории.
Tucker.md, 1–508	CP/Tucker и envelope: раздел 7. Исправлен знак ridge; пространственная гладкость не следует из low rank. Поле плоскостей не доказывает существование интегрируемого многообразия.
cladue.md, 5–57	Schur angle-search, retractions, norm families, GN, metric homotopy: разделы 5–8. Исправлены covariance w^2 , недостающий polar boundary и заявления о глобальном поиске/сходимости/Fisher без условий.

Подкаталоги documentatio, documentation, archive, pdf/PDF не использованы. Проверки формул и сборка находятся в SVD/theory_2026_10_01/. Проверки тождеств и узкий benchmark одной angle curve записаны отдельно; качество восстановления полного алгоритма не измерено.

В Научные предшественники и пределы обобщения

Направление	Что заимствуется и где заканчивается перенос результата
HJPS; MAVE [1, 2]	ADE structural adaptation и local regression EDR. Наш finite-sketch и штрафы имеют свои statistical assumptions.
VARPRO [3]	Исключение линейных coefficients и производные профиля; constant-rank либо augmented full-rank guard.
Edelman–Arias–Smith; GROUSE [4, 5]	SVD exponential и rank-one geodesic updates известны. Общие ADP-операторы/anisотропу не совпадают с sampling model GROUSE.
Weighted approximation; quotient low rank [6, 7]	Отсутствие обычного SVD closed form и совместная fixed-rank optimization; применимы к фиксированной гладкой цели, без EDR guarantee.
Matrix pursuit [9]	Greedy singular atoms и refit масштабов; curvature-normalized gain выводится здесь из конкретной квадратичной ADP-цели.
Kronecker; CP/Tucker [10, 11]	Разделимость операторов/поля, разные виды low rank; без гарантии SPD, spatial smoothness или точности усеечения.
Manifold local regression [12]	Intrinsic tangent-coordinate regression на manifold predictors; не тождественна varying EDR distribution в ambient regression.

Синтез объединяет эти конструкции через (4) и (5). Основное улучшение для данной задачи — использовать дешёвые точные reduced profiles после выбора простых поворотных плоскостей, а для пространственного обобщения факторизовать касательное поле до ретракции. Это конкретные выводы и предложения; их новизна относительно всей литературы и преимущество в восстановлении здесь не доказаны.

Список литературы

- [1] M. Hristache, A. Juditsky, J. Polzehl, V. Spokoiny. *Structure Adaptive Approach for Dimension Reduction*. Ann. Statist. 29(6), 1537–1566, 2001. [WIAS preprint 569 \(2000\)](#); [doi:10.1214/aos/1015345954](#).
- [2] Y. Xia, H. Tong, W. K. Li, L.-X. Zhu. *An Adaptive Estimation of Dimension Reduction Space*. JRSS B 64(3), 363–410, 2002. [doi:10.1111/1467-9868.03411](#).
- [3] G. H. Golub, V. Pereyra. *The Differentiation of Pseudo-Inverses and Nonlinear Least Squares Problems Whose Variables Separate*. SIAM J. Numer. Anal. 10(2), 413–432, 1973. [doi:10.1137/0710036](#).
- [4] A. Edelman, T. A. Arias, S. T. Smith. *The Geometry of Algorithms with Orthogonality Constraints*. SIAM J. Matrix Anal. Appl. 20(2), 303–353, 1998, §2.5.1–2.5.4. [Author PDF](#).
- [5] L. Balzano, R. Nowak, B. Recht. *Online Identification and Tracking of Subspaces from Highly Incomplete Information*. Allerton, 2010. [arXiv:1006.4046](#), §3.
- [6] N. Srebro, T. Jaakkola. *Weighted Low-Rank Approximations*. ICML, 2003. [Author PDF](#).
- [7] B. Mishra, G. Meyer, S. Bonnabel, R. Sepulchre. *Fixed-Rank Matrix Factorizations and Riemannian Low-Rank Optimization*. Comput. Stat. 29, 591–621, 2014; preprint 2012. [arXiv:1209.0430](#).
- [8] P.-A. Absil, J. Malick. *Projection-Like Retractions on Matrix Manifolds*. SIAM J. Optim. 22(1), 135–158, 2012. [Author page and manuscript](#).
- [9] Z. Wang, M.-J. Lai, Z. Lu, W. Fan, H. Davulcu, J. Ye. *Rank-One Matrix Pursuit for Matrix Completion*. PMLR 32(2), 91–99, 2014. [Original paper](#).
- [10] C. F. Van Loan, N. Pitsianis. *Approximation with Kronecker Products*. In: Linear Algebra for Large Scale and Real-Time Applications, 293–314, 1993. [Cornell technical report 92-109 \(1992\)](#).

- [11] T. G. Kolda, B. W. Bader. *Tensor Decompositions and Applications*. SIAM Review 51(3), 455–500, 2009. [Author page and manuscript](#).
- [12] M.-Y. Cheng, H.-T. Wu. *Local Linear Regression on Manifolds and its Geometric Interpretation*. JASA 108(504), 1421–1434, 2013. [arXiv:1201.0327](#).
- [13] C. Eckart, G. Young. *The Approximation of One Matrix by Another of Lower Rank*. Psychometrika 1, 211–218, 1936. [doi:10.1007/BF02288367](#).